Автоматическое построение временных признаков

KION · 30 000 пользователей · воспроизводимый эксперимент

NDCG@10: 0.47332 → 0.48440
Δ +0.01107; 95% ДИ [+0.00840, +0.01383]

Можно ли автоматически подобрать окна памяти и отношения между сущностями лучше ручного выбора? Сравниваются CatBoost на содержательном ручном наборе и тот же алгоритм с автоматически отобранными агрегатами.

95% интервал подтверждает положительную разность в основном протоколе. Но весь банк без отбора лучше: 0.49114 (seed 42). На полном каталоге популярность 0.14847 выше автоотбора 0.10332; перенос выигрыша не подтверждён. Основные значения выше - ансамбли трёх seed.

Дополнено: весь банк повторён с тремя seed, NDCG@10 0.49544. Выполнены контроль бюджета, второй временной срез и проверка на 5 000 других пользователях. Эти проверки добавлены после исходного теста и описаны в разделах 5-7.

Что выполнено

• Реальные данные: 5,476,251 строк в источнике; сохранены все 169,946 записей 30 000 случайных пользователей.

• 48 ручных признаков, банк из 128 признаков, автоматический поиск 11 групп и их сочетаний.

• Четыре последовательных временных части, фиксированные кандидаты, три seed, абляции и paired bootstrap по пользователям.

• Проверка полного доступного каталога для 210 случайных запросов, анализ холодных пользователей и реальные замеры стоимости.

Область вывода

Это офлайн-ранжирование наблюдавшихся событий, а не CTR. В KION нет журнала показов, а дата last_watch_dt агрегирована по паре. Вероятности и sampled NDCG нельзя напрямую переносить на весь каталог или пользовательскую удовлетворённость.

24 октября 2026 · Полный текст, код и инструкции: README.md и REPORT.md

1. Данные и временной протокол

Источник - официальный KION, data_original.zip, commit f69775be31fa5779907cf0a92ddedb70037fb5ae. Фактические даты: 2021-03-13 - 2021-08-22. Отдельный interactions.csv.zip уменьшен до 1,59 млн строк и не использован.

Равномерная выборка пользователей без возвращения, seed 42; отбор по активности отсутствует. Медиана истории: 2 записей, 90-й процентиль: 13. Истории не обрезаются. Повторных троек удалено: 0.

Часть	Начало	Конец исключён	Запросы
train	2021-07-05	2021-08-02	25,478
search	2021-08-02	2021-08-09	7,382
confirm	2021-08-09	2021-08-16	7,605
test	2021-08-16	2021-08-23	7,978

Положительная цель - все различные записи пользователя в день t. Фильм должен хотя бы раз встречаться до t в выбранных данных и ещё не встречаться у этого пользователя. Уже просмотренные объекты и неизвестные пока объекты не оцениваются.

Контроли: 50 уникальных объектов на запрос, 25 равномерных и 25 по прошлой популярности в степени 0.75. Положительные объекты перемешиваются с контролями. Будущие позитивы из контролей не удаляются.

Граница доступной информации

История строго date < t; окно w = [t-w,t). Из-за дневной точности все события текущего дня недоступны. События завершённого дня обновляют историю следующего дня, включая тестовый период; веса моделей остаются фиксированными.

Train обучает веса. Search выбирает гиперпараметры/признаки и early stopping. Confirm проверяет выбранные решения. selection.lock.json сохраняется до чтения тестовых таблиц кодом обучения.

В тесте оценено 12,968 из 13,224 исходных целей (98.06%). Это условная оценка по известным объектам, а не end-to-end recall всех событий. Подробное покрытие каждого split и SHA-256 кандидатов сохранены в audit.json.

total_dur и watched_pct исключены полностью. Справочники трактуются как статические: исторических версий метаданных нет. Дата последнего просмотра не позволяет восстановить ранние повторные просмотры; строгость кода не устраняет это ограничение источника.

2. Ручной baseline и автоматизация

Ручной набор

Категории пользователя и объекта, item ID, год выпуска, день недели; counts пользователя/объекта за 7/30 дней и всю историю; counts и доли user-genre/country/director/type; давность, длина наблюдаемой истории и число уникальных объектов.

В основных категориальных агрегатах берётся первый токен. Прямой pair_count сохраняется как проверка: при фильтрации уже виденных объектов он равен нулю. User ID как признак не используется.

Выбранные параметры: {'depth': 6, 'l2_leaf_reg': 3}. Максимум 450 деревьев, learning rate 0.08; LogLoss для обучения, early stopping по AUC (patience 50), выбор по NDCG@10. Настройка выполнена только на search.

Грамматика признаков

Операция	Автоматически проверяемые варианты
Окна counts/долей	1, 3, 10, 14, 60 дней для шести отношений
Экспоненциальная память	half-life 2, 10, 30 дней; sum(2^(-age/half-life))
Тренды	(count_7/7) / (count_30/30 + 0.1)
Сегментная популярность	Возрастная группа пользователя × объект
Все жанры	Jaccard с последним объектом, средняя/максимальная доля жанров в 30-дневной истории

Каждая дополнительная группа проверяется с бюджетом 180 деревьев; ручной контроль получает тот же бюджет. Затем проверяются сочетания лучших двух и трёх групп. Критерий - NDCG@10, минимальный прирост 0.0005, не более трёх групп. Выбранный набор переобучается с полным бюджетом.

Выбрано: decay_2d, window_3d, window_1d. Итого 74 признаков. На confirm рекомендован вариант automatic.

Это ограниченный поиск в заданной человеком грамматике, связанный с идеей Deep Feature Synthesis. Он автоматизирует выбор внутри пространства, но не изобретает любые отношения или SQL-запросы. Отдельная подтверждающая валидация снижает риск переобучения поиска.

3. Результаты и неопределённость

Модель	NDCG@10	Recall@10	ROC-AUC	LogLoss
Ручные признаки	0.47332	0.71530	0.84922	0.11112
Автоотбор	0.48440	0.71821	0.85197	0.10997
Весь банк	0.49114	0.73090	0.85537	0.10930
Без косвенных связей	0.42575	0.65802	0.82498	0.11622
Метаданные	0.31506	0.51071	0.70470	0.13461
Популярность 7d	0.40059	0.64455	0.79809	-
Популярность all	0.33254	0.55231	0.76017	-

Основная разность ансамблей: +0.01107; 95% ДИ [+0.00840, +0.01383]. Использован парный bootstrap по пользователям, 2000 повторений, seed 2026. Все запросы пользователя переносятся вместе; метрика усредняется по запросам.

Отдельные seed 42,43,44, среднее ± SD: ручные 0.47049 ± 0.00160; авто 0.48275 ± 0.00130. Ансамбль - средняя вероятность. Прочие строки - seed 42 или популярность; абляции сравниваются при одинаковом seed. ДИ условен на данном обучении и наборе данных.

Устойчивость к кандидатам

Режим	Модель	NDCG@10	Recall@10
Смешанные	Ручные признаки	0.47332	0.71530
Смешанные	Автоотбор	0.48440	0.71821
Равномерные	Ручные признаки	0.68320	0.87864
Равномерные	Автоотбор	0.68729	0.87999
Весь каталог	Ручные признаки	0.09875	0.16825
Весь каталог	Автоотбор	0.10332	0.17873
Весь каталог	Популярность 7d	0.14847	0.23294

Каталог: 210 случайных запросов, без сэмплирования контролей. Авто - ручные: Δ=+0.00456; ДИ [-0.01240, +0.02253]. Положительное различие не подтверждено; популярность описательно сильнее обеих моделей. Это каталог выбранной выборки.

NDCG использует бинарную релевантность и все цели дня; ties разрешаются по item ID. Sampled NDCG не оценивает без смещения каталожный NDCG. ROC-AUC и LogLoss относятся к искусственному распределению кандидатов; калиброванный CTR из них не следует.

4. Что сработало и почему

Одиночная группа	NDCG@10 search	Δ к тому же бюджету
decay_2d	0.50535	+0.01132
window_3d	0.50524	+0.01122
window_1d	0.50403	+0.01001
decay_30d	0.49383	-0.00019

Поиск групп на 180 деревьях не выбрал лучший набор для полного бюджета: весь банк оказался сильнее. Коррелирующие окна и взаимодействия могут объяснять это, но причинная польза отдельных групп не установлена. Таблица описывает search, а не независимые тестовые эффекты.

При seed 42 вклад косвенных исторических связей относительно абляции: +0.04355 NDCG@10. Отобранный набор относительно всего банка: -0.00746. Для этих описательных разностей отдельные ДИ не вычислялись.

Холодные пользователи

Модель	Warm NDCG@10	Cold NDCG@10	Cold запросов
Ручные признаки	0.45852	0.52720	1720
Автоотбор	0.46894	0.54064	1720

Cold означает отсутствие событий до даты запроса. Для такого пользователя история не помогает; остаются справочники, календарь и глобальная популярность. Пользователи с короткой историей не удалялись, поэтому оценка не ограничена только активными клиентами.

Самые важные признаки автоматической модели

Признак	Важность
item__ewm__h2	25.89
item_recency	13.08
item__count__30d	11.36
item__count__0d	7.67

PredictionValuesChange описывает использование признаков, а не причинность. Для согласованного анализа нужны абляции, вариация seed и независимый период. Даже выигрыш на тесте не доказывает рост пользовательской удовлетворённости.

Провал переноса на каталог может быть связан с законом контролей: классификатор различает позитивы и популярностный шум, а не оценивает каталожную вероятность события. Коррекция сэмплирования не применялась; причинный эффект распределения контролей не выделен.

5. Повторения и контроль бюджета

Дополнительный протокол сохранён до новых запусков в artifacts/additional/plan.lock.json. Исходный тест уже был известен, поэтому это post-hoc проверки; первоначальное сравнение и его результаты сохранены. Новый победитель не объявляется задним числом.

Полный банк: одинаковые три seed

Модель, ансамбль	NDCG@10	Recall@10	Отдельные seed, mean ± SD
Ручные признаки	0.47332	0.71530	0.47049 ± 0.00160
Автоотбор	0.48440	0.71821	0.48275 ± 0.00130
Весь банк	0.49544	0.73353	0.49378 ± 0.00301

Банк - ручные: +0.02212 [+0.01869; +0.02586]. Банк - отбор: +0.01105 [+0.00815; +0.01410]. ДИ: paired user-bootstrap, 2000 повторений. Банк seed 42 побитово воспроизводит исходные предсказания.

3 набора × 2 лимита × 3 seed

Период	Лимит	Ручные	Отбор	Банк	Банк - отбор
search	180	0.49706	0.50836	0.51542	+0.00706
search	450	0.50497	0.51525	0.52351	+0.00826
confirm	180	0.48322	0.50008	0.51026	+0.01018
confirm	450	0.49035	0.50371	0.51621	+0.01250

Данные, признаки, кандидаты, параметры и early stopping зафиксированы; меняется только лимит 180/450. На confirm проверяем D = (bank450 - selected450) - (bank180 - selected180). D = +0.00232 [-0.00064; +0.00522].

Интервал взаимодействия включает ноль. Объяснять потери отбора одним только коротким обучением нельзя: этот механизм не подтверждён.

Банк - отбор на search при 180: +0.00706 [+0.00418; +0.01004]. Поиск рассматривает лишь одиночные группы и top-2/top-3, исключая весь банк из кандидатов. Ограниченное пространство может пропустить полезное сочетание. Диагностический контроль не используется для нового выбора по тесту.

6. Повторение на другом периоде

Тот же источник, 30 000 пользователей и полный набор предоставленных записей. Train 14.06-11.07, search 12-18.07, confirm 19-25.07, test 26.07-01.08. Все даты 2021 года. Веса учатся заново; внутри каждого дня доступна только прошлая история.

Depth=6 и l2=3 заморожены заранее. Отбор 11 групп повторён на раннем search. Выбраны window_1d, window_3d, multigenre; 71 признаков. Решение sealed до чтения нового test. Все три варианта получают три seed.

Модель	NDCG@10, новый test	Recall@10
Ручные признаки	0.49704	0.74613
Автоотбор	0.51714	0.75925
Весь банк	0.51603	0.75884

Авто - ручные: +0.02011 [+0.01648; +0.02388]. Банк - ручные: +0.01900 [+0.01524; +0.02264]. Банк - отбор: -0.00111 [-0.00366; +0.00115].

Полный каталог: обе недели

Неделя	Модель, 210 запросов	NDCG@10	Recall@10
16-22.08	Ручные признаки	0.09875	0.16825
16-22.08	Автоотбор	0.10332	0.17873
16-22.08	Весь банк	0.10454	0.16246
16-22.08	Популярность 7d	0.14847	0.23294
26.07-01.08	Ручные признаки	0.16745	0.26195
26.07-01.08	Автоотбор	0.15676	0.27012
26.07-01.08	Весь банк	0.16144	0.28730
26.07-01.08	Популярность 7d	0.17724	0.31065

Банк - популярность: 16-22.08 -0.04393 [-0.07709; -0.00822]; 26.07-01.08 -0.01579 [-0.05047; +0.02127]. Каталожные score не корректировались и не использовались для настройки.

Тестовые недели не пересекаются, но пользователи и истории повторяются; июльские исходы входили в первый train, а гиперпараметры перенесены из более позднего исследования. Это ретроспективная проверка чувствительности к периоду, не независимый проспективный holdout. Интервалы недель не объединяются как независимые. Вторичные проверки без поправки на множественные сравнения.

7. Другие пользователи: отдельный контроль

План зафиксирован до выборки в artifacts/independent/plan.lock.json. Из 932 179 пользователей вне исходной когорты равномерно без возвращения выбраны 5 000, seed 2027. Нет фильтра активности. Пересечение с исходными 30 000: ноль пользователей.

Сохранены все 28,907 предоставленных записей. Аудит заново извлекает их из raw CSV и проверяет случайную выборку. Даты исходного августовского протокола сохранены; все split содержат только новую когорту. В тесте 1,308 запросов и 838 пользователей, объекты вне известного каталога исключены.

Общие параметры заморожены до новых результатов. Отбор выполнен заново на search новой когорты: multigenre, decay_30d, decay_2d; 63 признаков. Все варианты - три seed. Счётчики и каталог строятся только по новой когорте; события исходных пользователей не используются.

Модель, 3 seed	NDCG@10	Recall@10	ROC-AUC
Ручные признаки	0.43819	0.67139	0.81946
Автоотбор	0.45044	0.67698	0.82410
Весь банк	0.45642	0.67895	0.82434

Авто - ручные: +0.01226 [+0.00372; +0.02082]. Банк - ручные: +0.01823 [+0.00900; +0.02785]. Банк - отбор: +0.00598 [-0.00072; +0.01261].

Ограничение: на uniform-кандидатах этой когорты авто - ручные -0.00087 [-0.00912; +0.00767]; банк - ручные +0.00546 [-0.00335; +0.01416]. Подтверждение в смешанном пуле не доказывает устойчивость к любому распределению контролей; исходы uniform также включены в метрики.

Полный каталог новых пользователей

Модель, 210 запросов	NDCG@10	Recall@10
Ручные признаки	0.13354	0.20472
Автоотбор	0.13665	0.22377
Весь банк	0.13359	0.20373
Популярность 7d	0.14852	0.23500

Банк - популярность: -0.01493 [-0.04499; +0.01396]. Интервалы вторичные, без поправки на множественные сравнения; каталог не используется для нового выбора модели.

Новые пользователи не участвовали в настройке исходного исследования. Это более отдельная пользовательская проверка, однако источник, объекты и календарь остаются общими. Каталоги двух когорт различаются; абсолютные NDCG между когортами нельзя трактовать как чистый эффект переноса. Сравнения методов проводятся внутри когорты.

8. Стоимость, воспроизведение и пределы

Основные таблицы признаков: 114.3 с. Сумма fit вариантов: 62.6 мин. Пиковый RSS основного процесса: 4021 МиБ. CPU, 6 потоков на обучение. Две абляции считались параллельно; общий RSS процессов не измерялся. Версии - environment.json. Стоимость поиска включена.

Дополнения: 9 новых fit, 24.6 мин. Временная репликация: 24 артефактов, 62.9 мин fit. Новые 5k пользователей: 24 артефактов, 30.4 мин fit. Процессы запускались параллельно: 6 потоков на fit основных дополнений, 2 у новой когорты. Сумма fit не равна времени ожидания; совокупный RSS не измерен.

Однодневный микробенчмарк (31.07.2021, один повтор)

Пользователи	История целиком	Строки кандидатов	Признаки, с	Frame, МиБ
1000	5617	1745	0.13	2.2
10000	56605	17912	0.53	22.8
30000	169946	55860	1.35	71.2

Pandas повторно группирует историю по дням и окнам; реализация не готова к миллиардам событий. Нужны инкрементальные оконные счётчики и состояния затухания, SQL/streaming-агрегации, партиционирование и retrieval перед ранжированием. Время на миллиардах событий не экстраполировалось.

Воспроизведение

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install -r requirements.txt
make reproduce PYTHON=python
```

Нужны интернет для pinned KION и зависимости. Raw data, кэши, модели и предсказания остаются локально; компактный архив содержит код, отчёты и проверяемые результаты. При изменении конфигурации используйте новый output_dir. unit tests и recsys.validate проверяют временные границы, будущие события, кандидатов, метрики и checksums.

Ограничения

Один датасет и два ретроспективных временных среза; 30 000 пользователей; неизвестные объекты исключены; last_watch_dt агрегирован; справочники не имеют as-of снимков; нет показов и достоверных негативов; источнику добавлен шум. Полный каталог проверен на подмножестве запросов. Yambda и альтернативные нейросети не исследовались. Нужны независимый период и затем онлайн-проверка.

Источники

Petrov et al., MTS Kion Dataset, CARS@RecSys 2022

Kanter & Veeramachaneni, Deep Feature Synthesis, 2015

Prokhorenkova et al., CatBoost, NeurIPS 2018

Krichene & Rendle, On Sampled Metrics, KDD 2020